

DESAFIO DE DADOS

Altura

Contexto

A base de dados **inventario.xlsx** que vocês vão usar não é um exemplo fictício de livro-texto, é um **inventário florestal real**, de um talhão de eucalipto:

Variável	Valor no talhão
Filial	2
Talhão	8
Idade	7 anos
Regime	Reforma
Espaçamento	3 × 3 m
Clone	1501
Mês de plantio	9
Sítio	1
Parcelas amostradas	6 (numeradas de 1 a 6)
Árvores no total	215

Dicionário de colunas:

Coluna	Significado
PARCELA	Número da parcela (unidade amostral) dentro do talhão
FILEIRA	Linha de plantio dentro da parcela (1 a 7)
ÁRVORE	Número sequencial da árvore dentro da parcela
DAP	Diâmetro à altura do peito (cm)
HT	Altura total (m) — atenção: nem toda árvore tem HT medida

Cada parcela tem 7 fileiras de árvores, com um número variável de árvores por fileira (efeito de falhas/replantio no talhão). O DAP foi medido em todas as 215 árvores. Já a altura (HT) aparece como 0 em boa parte das linhas, isso não é erro nem falta de digitação: é uma decisão de amostragem que faz parte do problema a ser resolvido.

O problema

Ao abrir a base, vocês vão notar que a altura (HT) está zerada em quase metade das árvores. Isso não é erro: é uma prática comum em inventário florestal, medir a altura de todas as árvores é caro e demorado, então mede-se altura apenas em uma subamostra, e o restante é estimado por meio de uma relação estatística entre DAP e altura (a chamada relação hipsométrica).

Neste talhão, a altura foi medida apenas nas fileiras centrais de cada parcela (fileiras 3, 4 e 5); nas fileiras 1, 2, 6 e 7, HT = 0 significa "não medida". O desafio de vocês é:

1. Identifiquem o padrão de amostragem de altura. Confirmem, explorando os dados, em quais fileiras a altura foi de fato medida.
2. Construam a relação hipsométrica (DAP $\times$ HT) usando apenas as árvores com altura medida. Testem pelo menos um modelo simples (ex.: linear; se quiserem, comparem com uma transformação logarítmica ou outro modelo à escolha do grupo) e avaliem a qualidade do ajuste (R^2 , análise gráfica dos resíduos).
3. Apliquem o modelo ajustado para estimar a altura das árvores não medidas (fileiras 1, 2, 6 e 7), gerando uma base de dados completa (215 árvores, todas com altura, medida ou estimada).
4. Recalculem a altura média (e, se quiserem, a altura dominante, analisem diferentes conceitos de árvore dominante e escolham o mais usado) por parcela usando a base completa, e comparem com o que se obteria se vocês (erradamente) calculassem a média apenas com as árvores medidas.
5. Discussão crítica: quais são os riscos/limitações de usar uma subamostra sistemática (só as fileiras centrais) para representar toda a parcela? Isso poderia gerar viés? Em que direção?

Entrega (GitHub)

- Script comentado com o ajuste do modelo e a aplicação às árvores não medidas.
- Gráfico de dispersão DAP $\times$ HT com a curva/reta ajustada.
- Base de dados final (com a coluna de altura completa: medida ou estimada, identificando qual é qual).
- Relatório curto com a discussão crítica do item 5.